

# REDES NEURAIS E DEEP LEARNING

*Prof. Me. José Paulo Diogo Júnior*



EDITORA

**Prominas**

---

**Prof. Me. José Paulo Diogo Júnior**

# **REDES NEURAIS E DEEP LEARNING**

**1ª edição**  
**Ipatinga – MG**  
**2024**

# EDITORIAL

## EDITORA PROMINAS EDITORIAL

**Diretor Geral:** Valdir Henrique Valério

**Diretor Executivo:** William José Ferreira

**Ger. do Núcleo de Educação a Distância:** Cristiane Lelis dos Santos

**Coord. Pedag. da Equipe Multidisciplinar:** Cristiane Lelis dos Santos

**Revisão Gramatical e Ortográfica:** Elislaine Patricia dos Santos Gomes

**Revisão/Diagramação/Estruturação:** Bruna Luiza Mendes Leite

Lorena Oliveira Silva Portugal

**Design:** Bárbara Carla Amorim O. Silva

Élen Cristina Teixeira Oliveira

Cristiano Soares Andrade

© 2024, Editora Prominas.

Este livro ou parte dele não podem ser reproduzidos por qualquer meio sem Autorização escrita do Editor.

**NEaD – Núcleo de Educação a Distância FACULDADE ÚNICA**

Rua Salerno, 299

Anexo 03 – Bairro Bethânia – CEP: 35164-779 – Ipatinga/MG

Tel (31) 2109 -2300 – 0800 724 2300

[www.faculdadeunica.com.br](http://www.faculdadeunica.com.br)



EDITORA  
**Prominas**

# LEGENDA DE ÍCONES

Com o intuito de facilitar o seu estudo e uma melhor compreensão do conteúdo aplicado ao longo do livro didático, você irá encontrar ícones ao lado dos textos. Eles são para chamar a sua atenção para determinado trecho do conteúdo, cada um com uma função específica, mostradas a seguir:



## **FIQUE ATENTO**

Trata-se dos conceitos, definições e informações importantes nas quais você precisa ficar atento.



## **BUSQUE POR MAIS**

São opções de links de vídeos, artigos, sites ou livros da biblioteca virtual, relacionados ao conteúdo apresentado no livro.



## **VAMOS PENSAR?**

Espaço para reflexão sobre questões citadas em cada unidade, associando-os a suas ações.



## **FIXANDO O CONTEÚDO**

Atividades de múltipla escolha para ajudar na fixação dos conteúdos abordados no livro.



## **GLOSSÁRIO**

Apresentação dos significados de um determinado termo ou palavras mostradas no decorrer do livro.



---

# SUMÁRIO

|                                           |           |
|-------------------------------------------|-----------|
| <b>REDES NEURAI E DEEP LEARNING .....</b> | <b>1</b>  |
| 1. Introdução às redes neurais .....      | 6         |
| 2. Redes neurais profundas .....          | 9         |
| 3. Treinamento e otimização .....         | 11        |
| 4. Aplicações de deep learning .....      | 14        |
| <b>FIXANDO O CONTEÚDO .....</b>           | <b>17</b> |
| <b>GABARITO .....</b>                     | <b>20</b> |
| <b>REFERÊNCIAS BIBLIOGRÁFICAS .....</b>   | <b>21</b> |

## CONFIRA A SEGUIR

Nesta aula será introduzido sobre os assuntos referentes a Redes Neurais, Deep Learning e formas de treinamento de Inteligência Artificial.

---

## 1. INTRODUÇÃO ÀS REDES NEURAIS

As redes neurais artificiais (RNA) são um dos pilares fundamentais da inteligência artificial moderna, inspiradas diretamente no funcionamento do cérebro humano. Essas redes são compostas por unidades chamadas neurônios artificiais, que imitam o comportamento dos neurônios biológicos. Um neurônio artificial recebe múltiplas entradas, realiza uma combinação ponderada dessas entradas e, em seguida, aplica uma função de ativação para determinar a saída. A arquitetura de uma rede neural geralmente consiste em uma camada de entrada, uma ou mais camadas ocultas, e uma camada de saída. As camadas ocultas são onde ocorre o aprendizado mais profundo e a abstração de padrões complexos nos dados.

A motivação inicial para o desenvolvimento das redes neurais veio do desejo de replicar a capacidade do cérebro humano de reconhecer padrões e tomar decisões com base em dados incompletos ou ambíguos. As primeiras tentativas de criar modelos de redes neurais ocorreram na década de 1940, mas foi apenas nas décadas de 1980 e 1990 que as RNAs começaram a ganhar popularidade, graças ao avanço no poder computacional e ao desenvolvimento de algoritmos mais eficientes de aprendizado (Haykin, 2020).

O funcionamento de uma rede neural é baseado na ideia de aprendizado por experiência, isso significa que a rede é treinada com um conjunto de exemplos e ajustar seus parâmetros para melhorar seu desempenho em tarefas específicas, como classificação ou regressão. Durante o treinamento supervisionado, a rede é alimentada com pares de entrada e saída com o objetivo de minimizar a diferença entre as previsões da rede e as saídas reais. Este processo de minimização é realizado através de uma técnica conhecida como *backpropagation*, onde os erros são propagados de volta pela rede, permitindo o ajuste iterativo dos pesos.

Além do aprendizado supervisionado, as redes neurais também podem ser treinadas de maneira não supervisionada ou por reforço. No aprendizado não supervisionado, a rede tenta encontrar padrões intrínsecos nos dados sem rótulos específicos, enquanto no aprendizado por reforço, a rede aprende a tomar decisões sequenciais, recebendo recompensas ou penalidades com base nas ações tomadas.


---

As redes neurais têm demonstrado grande sucesso em uma variedade de aplicações, desde a identificação de padrões em grandes conjuntos de dados até a modelagem de processos biológicos complexos. O desenvolvimento e o treinamento de redes neurais não estão isentos de desafios, sendo um dos principais problemas enfrentados durante o treinamento de redes profundas, com muitas camadas ocultas, é o problema do gradiente desaparecido. Esse problema ocorre quando os gradientes, usados para atualizar os pesos durante o treinamento, se tornam extremamente pequenos, resultando em mudanças insignificantes nos pesos e, conseqüentemente, em um treinamento ineficaz. Uma forma de mitigar esse problema é a normalização de lotes (*batch normalization*), que ajuda a estabilizar e acelerar o treinamento além da escolha de funções de ativação mais adequadas, como a ReLU (*Rectified Linear Unit*), que não sofre de saturação como as funções sigmóides tradicionais (Haykin, 2020).

Outro aspecto fundamental no estudo das redes neurais é a compreensão do papel dos hiperparâmetros, como a taxa de aprendizado, o número de neurônios em cada camada, e o número de camadas ocultas. Esses parâmetros influenciam diretamente o desempenho da rede e sua capacidade de generalização. A escolha adequada dos hiperparâmetros é crucial para o sucesso do modelo, e muitas vezes requer experimentação cuidadosa e validação cruzada.

A figura a seguir mostra resumidamente o processo de treinamento de uma rede neural.

**Figura 1:** Processo de Treinamento de Rede Neural



**Fonte:** Elaborado pelo autor (2024)

Na figura anterior é possível visualizar um diagrama simples do procedimento de treinamento de IA.

#### GLOSSÁRIO

O **backpropagation** é o algoritmo-chave que faz o treinamento de modelos profundos algo computacionalmente tratável. Para as redes neurais modernas, ele pode tornar o treinamento com gradiente descendente até dez milhões de vezes mais rápido, em relação a uma implementação ingênua.

#### FIQUE ATENTO

Tamanho do lote (Batch Size) é um termo usado em aprendizado de máquina e refere-se ao número de exemplos de treinamento usados em uma iteração. O Batch Size pode ser uma das três opções: batch mode: onde o tamanho do lote é igual ao conjunto de dados total, tornando os valores de interação e épocas equivalentes.

---

## 2. REDES NEURAIS PROFUNDAS

As redes neurais profundas (DNNs) representam uma evolução natural das redes neurais tradicionais, caracterizadas por possuírem um grande número de camadas ocultas, o que lhes permite modelar relações complexas nos dados. O termo "profundo" refere-se à profundidade da rede, ou seja, ao número de camadas que os dados precisam atravessar desde a entrada até a saída. Essa profundidade permite que as DNNs capturem características hierárquicas nos dados, onde camadas mais baixas aprendem representações simples, como bordas ou texturas em imagens, enquanto camadas mais altas combinam essas características para formar representações mais abstratas, como formas ou objetos completos (Haykin, 2020).

A explosão do deep learning, impulsionada pelas DNNs, ocorreu em grande parte devido à combinação de três fatores:

- 1) O aumento do poder computacional, especialmente com o advento das GPUs (unidades de processamento gráfico) que aceleram o treinamento de redes;
- 2) A disponibilidade de grandes volumes de dados, essenciais para treinar redes profundas;
- 3) O desenvolvimento de novas técnicas e arquiteturas, como redes convolucionais (CNNs) e redes recorrentes (RNNs), foram projetadas para tarefas específicas e alcançaram resultados de ponta em áreas como visão computacional e processamento de linguagem natural.

As redes convolucionais revolucionaram o campo da visão computacional ao utilizarem operações de convolução, que permitem a extração automática de características espaciais em imagens. Essas características são combinadas em camadas posteriores para identificar objetos, faces, ou outros elementos visuais. A capacidade das CNNs de aprender filtros de convolução diretamente dos dados, sem a necessidade de intervenção manual, tornou-as extremamente poderosas em tarefas como reconhecimento de imagem e detecção de objetos.


Estas redes neurais recorrentes (RNNs) são projetadas para lidar com dados sequenciais, onde a ordem dos elementos é crucial como em textos, séries temporais, e sinais de áudio. As RNNs possuem conexões que formam

---

ciclos, permitindo que a informação persista e seja propagada ao longo de uma sequência. As RNNs tradicionais enfrentam dificuldades com sequências longas devido ao problema do gradiente desaparecido, semelhante ao que ocorre em redes profundas. Para conseguirmos superar essas limitações, foram desenvolvidas arquiteturas como LSTM (*Long Short-Term Memory*) e GRU (*Gated Recurrent Units*), que permitem a captura de dependências de longo prazo de maneira mais eficiente (Haykin, 2020).

Um dos grandes desafios no treinamento de DNNs é a necessidade de uma quantidade substancial de dados rotulados que, geralmente, podem ser custosos e demorados de obter. Uma maneira de mitigar essa necessidade é a aplicação de técnicas como aprendizado por transferência, onde um modelo pré-treinado em uma grande base de dados é ajustado para uma nova tarefa com menos dados, tornaram-se populares. Além disso, técnicas de data augmentation, que envolvem a criação de novas amostras de dados a partir das existentes através de transformações como rotação, escala, ou adição de ruído, ajudam a aumentar a robustez do modelo e melhorar seu desempenho. Um esquema em rede neural é apresentado na figura abaixo com um resumo do processo de massificação do *Deep Learning* (Lima, 2014).

**Figura 2:** Massificação do uso de Deep Learning



**Fonte:** elaborado pelo autor (2024)

Na figura anterior pode-se ver de forma resumida quais foram os fatores que aceleraram o uso do Deep Learning.

### 3. TREINAMENTO E OTIMIZAÇÃO

O treinamento de redes neurais, mais especificamente as profundas, é um processo iterativo e intensivo, que envolve a otimização de uma função de custo para que a rede possa fazer previsões precisas em novos dados. A função de custo, também conhecida como função de perda, mede o erro entre as previsões da rede e os valores reais. O objetivo deste treinamento é minimizar essa função de custo ajustando os pesos das conexões entre neurônios.

O algoritmo de gradiente descendente é a técnica de otimização mais comumente utilizada no treinamento de redes neurais. O gradiente descendente calcula o gradiente da função de custo em relação aos pesos e usa essa informação para mover os pesos na direção que reduz a função de custo. Em outras palavras, ele ajusta os pesos de forma a minimizar o erro da

---

rede. Existem várias variantes do gradiente descendente, como o gradiente descendente estocástico (SGD), que atualiza os pesos com base em um único exemplo de treinamento, e o Adam (Adaptive Moment Estimation), que ajusta dinamicamente as taxas de aprendizado para cada peso com base em momentos de gradiente passados (Haykin, 2020).

O processo de treinamento é realizado em lotes sendo feitos da seguinte forma:

- Os dados de treinamento são divididos em pequenos subconjuntos chamados de batches.
- Cada batch é usado para calcular o gradiente e atualizar os pesos.

Dessa forma não só se acelera o treinamento, mas também adiciona uma forma de regularização que ajuda a evitar o overfitting, um problema onde a rede se ajusta muito bem aos dados de treinamento, mas não consegue generalizar para novos dados.

A escolha da taxa de aprendizado é crítica no treinamento de redes neurais. Ao aplicar uma taxa de aprendizado muito alta pode-se fazer com que o treinamento oscile e nunca converja, enquanto uma taxa muito baixa pode tornar o processo extremamente lento e levar a uma solução subótima. Algumas técnicas como o decaimento da taxa de aprendizado, onde a taxa é reduzida gradualmente durante o treinamento, e o uso de otimizadores avançados como Adam, que ajustam a taxa de aprendizado para cada peso individualmente, são amplamente utilizadas para melhorar a eficiência e a eficácia do treinamento.

Além do ajuste dos pesos, no treinamento de redes profundas também envolve a escolha e ajuste de hiperparâmetros, como o número de camadas ocultas, o número de neurônios em cada camada, e o tipo de função de ativação. A validação cruzada é frequentemente usada para testar diferentes combinações de hiperparâmetros e encontrar a configuração que oferece o melhor desempenho (Haykin, 2020). Na figura a seguir pode-se ver os pontos positivos e negativos do uso de técnicas de treinamento de redes neurais.

**Figura 3:** Prós e Contras de Técnicas de Treinamento de Redes Neurais



**Fonte:** Elaborado pelo autor (2024)

As relações do treinamento de redes neurais são visualizadas na figura divididas em atividades prós e contras.

Todo o processo de treinamento pode ser acompanhado e refinado usando várias técnicas de monitoramento, como a visualização das curvas de aprendizado, que mostram como a função de custo e a acurácia mudam ao longo do tempo, permitindo identificar problemas como o overfitting e tomar medidas corretivas (Lima, 2014).

---

## 4. APLICAÇÕES DE DEEP LEARNING

O deep learning tem revolucionado várias indústrias e áreas de pesquisa ao fornecer soluções altamente precisas e automatizadas para problemas complexos. Uma das áreas mais impactadas é a visão computacional, onde redes convolucionais (CNNs) são usadas para tarefas como reconhecimento de objetos, análise de imagens médicas, e vigilância. As CNNs são capazes de identificar padrões visuais em dados de imagem que seriam difíceis ou impossíveis de detectar com técnicas tradicionais, o que levou a avanços significativos em áreas como a condução autônoma e a detecção precoce de doenças (Haykin, 2020).

No processamento de linguagem natural (NLP), modelos baseados em redes neurais, como transformers e redes neurais recorrentes (RNNs), têm sido fundamentais em aplicações como tradução automática, geração de texto, e análise de sentimentos. A capacidade desses modelos de entender e gerar linguagem natural abriu novas possibilidades em assistentes virtuais, chatbots, e sistemas de recomendação.


Uma outra aplicação crucial do deep learning é em jogos, onde técnicas de aprendizado por reforço profundo (Deep Reinforcement Learning) têm sido usadas para treinar agentes que podem superar o desempenho humano em jogos complexos, como xadrez, Go e videogames. Alguns algoritmos como o Deep Q-Network (DQN) e o AlphaGo da DeepMind combinam redes neurais com aprendizado por reforço para aprender estratégias vencedoras sem supervisão humana direta, baseando-se apenas na interação com o ambiente de jogo (Haykin, 2020).

Na área de saúde, o deep learning está sendo utilizado para desenvolver sistemas de diagnóstico assistido por IA, que podem analisar grandes quantidades de dados médicos e identificar sinais de doenças em estágios iniciais, tendo o potencial de melhorar a precisão e a rapidez do diagnóstico, além de reduzir a carga de trabalho dos profissionais de saúde. Já em finanças, modelos de deep learning são aplicados para prever tendências de mercado, analisar riscos, e detectar fraudes em tempo real.

Além dessas aplicações, o *deep learning* também está começando a ser explorado em áreas emergentes, como arte e música, onde redes neurais são

usadas para criar obras de arte e composições musicais de forma autônoma, sendo esta uma combinação de *deep learning* com outras técnicas, como redes generativas adversariais (GANs), permitiu a geração de imagens, vídeos, e até mesmo *deepfakes*, que são cada vez mais difíceis de distinguir da realidade.

**Figura 4:** Áreas de atuação do Deep Learning



**Fonte:** Elaborado pelo autor (2024)

Na figura a seguir pode-se compreender melhor sobre todas as áreas em que o Deep Learning pode ser utilizado.

Os avanços em *deep learning*, no entanto, também trazem desafios éticos e sociais significativos, pois o uso de IA em decisões automatizadas levanta questões sobre transparência, responsabilidade, e justiça, especialmente em áreas sensíveis como a justiça criminal e o emprego. O impacto da automação na força de trabalho e a privacidade dos dados também são preocupações importantes que precisam ser abordadas à medida que a tecnologia avança.



### VAMOS PENSAR

A **introdução da Inteligência artificial** está sendo cada vez melhor empregada em jogos eletrônicos nos NPCs para gerar conversas e interações cada vez mais reais. Como isso pode ser empregado em empresas de marketing e vendas?



### BUSQUE POR MAIS

Você sabia que o Metaverso ganhou força com o uso das IAs para auxiliar na criação e gerenciamento destes espaços? Disponível em: <https://shre.ink/g9Ha>. Acesso em: 10 out. 2024.



---

## **FIXANDO O CONTEÚDO**

1. Qual é a principal inspiração para o desenvolvimento das redes neurais artificiais?
  - a) Estruturas de sistemas operacionais.
  - b) Redes de comunicação de dados.
  - c) Funcionamento do cérebro humano.
  - d) Circuitos eletrônicos tradicionais.
  - e) Modelos matemáticos de física.
  
2. Em uma rede neural, a camada de entrada é responsável por:
  - a) Gerar a saída final da rede.
  - b) Processar internamente os dados.
  - c) Ajustar os pesos das conexões.
  - d) Receber os dados brutos.
  - e) Normalizar os gradientes.
  
3. Qual é a função principal do algoritmo de gradiente descendente em uma rede neural?
  - a) Aumentar a complexidade da rede.
  - b) Ajustar os pesos para minimizar a função de custo.
  - c) Selecionar os dados mais relevantes para o treinamento.
  - d) Reduzir o número de camadas da rede.
  - e) Melhorar a velocidade de processamento.
  
4. **(IF-SP – Adaptado)** Redes Neurais Artificiais são técnicas computacionais que utilizam um modelo matemático inspirado no neurônio biológico, obtendo aprendizado pela experiência. Encontra aplicações em visão computacional, automação residencial e industrial, robótica, microeletrônica, entre outros. A respeito de redes neurais MLP (Multi-layer Perceptron), analise as afirmativas:
  - I. Os parâmetros a serem definidos para a execução de uma rede MLP são número de camadas, número de neurônios em cada camada, taxa de aprendizado e função de ativação.
  - II. São redes recorrentes.

- 
- III. Os neurônios da camada oculta são capazes de capturar a não-linearidade dos dados.
- IV. Geralmente utiliza-se a função sigmoide como função de ativação nas camadas ocultas e de saída.
- a) I e IV apenas.
- b) I e III apenas.
- c) I, II e IV apenas.
- d) I, III e IV apenas.
- e) Todas as alternativas estão corretas.
- 5.** Qual técnica é utilizada para evitar o desaparecimento do gradiente em redes neurais profundas?
- a) Normalização de lotes (batch normalization).
- b) Redução do número de camadas ocultas.
- c) Uso de funções de ativação lineares.
- d) Aumento da taxa de aprendizado.
- e) Exclusão das camadas de entrada.
- 6.** Qual técnica é usada para ajustar dinamicamente a taxa de aprendizado durante o treinamento de uma rede neural?
- a) Dropout.
- b) Gradiente descendente.
- c) Batch normalization.
- d) Aprendizado adaptativo.
- e) Decaimento de taxa de aprendizado.
- 7.** Qual é uma aplicação típica de aprendizado por reforço em deep learning?
- a) Análise de imagens médicas.
- b) Treinamento de agentes em jogos.
- c) Detecção de fraudes financeiras.
- d) Processamento de linguagem natural.
- e) Geração de texto.

---

**8. (UNICAMP – Adaptado)** “Alguns algoritmos de inteligência artificial (IA) são desenvolvidos para aprender a reconhecer a música preferida do usuário, o gênero de filmes que lhe interessa, os assuntos que busca no jornal. O objetivo desse tipo de programação é identificar padrões – e, assim, automatizar decisões e facilitar a vida das pessoas. No entanto, por serem feitos para assimilar modelos de comportamento, os algoritmos também podem replicar atitudes que reforçam o racismo, a misoginia e a homofobia. Absorvem, reproduzem e, como resultado, robustecem a discriminação e a intolerância nas mais variadas formas”.

Suzel Tunes, “**Algoritmos parciais**”. Pesquisa Fapesp. <https://revista.pesquisa.fapesp.br/algoritmos-parciais/>. Acessado em: 08 nov. 2020.

A partir do excerto e das informações sobre algoritmos de inteligência artificial, é correto afirmar:

- a) Esses algoritmos expressam vieses políticos e alimentam a indústria de *fake news*, a partir da padronização definida pelas grandes corporações de tecnologia, e favorecem a construção de “bolhas” no mundo real.
- b) Ao automatizar a escolha das pessoas, os sistemas de aprendizagem de máquina perpetuam preconceitos, de forma intencional ou não, pois o sistema de dados é alimentado pelos próprios seres humanos.
- c) Os algoritmos são concebidos por princípios e lógicas técnicas neutras, mas a manipulação e o uso distorcido de suas informações são de responsabilidade exclusiva dos usuários.
- d) A concepção dos algoritmos e seus usos restringem a autonomia e anulam a capacidade de escolha das pessoas, induzindo-as à aceitação de informações e produtos.
- e) Os programadores de IA não tem qualquer forma de prever esse tipo de acontecimento.

---

## GABARITO

|           |   |
|-----------|---|
| QUESTÃO 1 | C |
| QUESTÃO 2 | D |
| QUESTÃO 3 | B |
| QUESTÃO 4 | B |
| QUESTÃO 5 | A |
| QUESTÃO 6 | E |
| QUESTÃO 7 | B |
| QUESTÃO 8 | A |

---

## REFERÊNCIAS BIBLIOGRÁFICAS

ALPAYDIN, Ethem. **Introduction to Machine Learning**. ed. 4. Editora MIT Press, 2020.

BHARGAVA, Aditya Y. **Entendendo Algoritmos: Um guia ilustrado para programadores e outros curiosos**. Novatec Editora, 2018.

GABRIEL, Martha. **Inteligência Artificial: Do Zero ao Metaverso**. Disponível em: Minha Biblioteca, Grupo GEN, 2022.

HAYKIN, Simon. **Redes Neurais**. ed.2 Bookman Editora, 2020.

KELLEHER, John D. **Deep Learning**. Editora MIT Press, 2019.

LUGER, George. **Inteligência Artificial**. 6. Pearson Editora, 2013.

SEBESTA, Robert W. **Conceitos de Linguagens de Programação**. 11. Bookman Editora, 2018.

SILVA, Fabrício, M. et al. **Inteligência artificial**. Disponível em: Minha Biblioteca, Grupo A, 2018.

LIMA, Isaías. **Inteligência Artificial**. Rio de Janeiro: Grupo GEN, 2014. E-book. ISBN 9788595152724. Disponível em: <https://shre.ink/gH7S>. Acesso em: 18 set. 2024.

SANCTIS, F.M. D. **Inteligência Artificial e Direito**. São Paulo: Grupo Almedina (Portugal), 2020. 9786556270890. Disponível em: <https://shre.ink/gH7e>. Acesso em: 19 Jul 2021.

BEN, C. **Inteligência Artificial**. Rio de Janeiro: Grupo GEN, 2010. 978-85-216-2936-8. Disponível em: <https://shre.ink/gH7b>. Acesso em: 19 Jul 2021.

LUCIAN, L. M. **Fundamentos de Aprendizagem de Máquina**. Porto Alegre: Grupo A, 2020. 9786556900902. Disponível em: <https://shre.ink/gH7g>. Acesso em: 19 jul 2021.



EDITORA  
**Prominas**